






Comparación de técnicas de computación paralela, contenedores y cloud computing para acelerar procesos de web scraping


Introducción



Web Scraping: clave para recolectar datos desde sitios web con aplicaciones en análisis de mercado, investigación y más.



Métodos secuenciales tradicionales enfrentan **problemas de rendimiento y escalabilidad** ante el crecimiento del volumen y la complejidad de los datos.




Modelos modernos basados:

- computación paralela
- contenedores (como Docker)
- servicios en la nube

Objetivo

Evaluar y comparar computación paralela, contenedores y nube para optimizar procesos de web scraping, usando como caso de estudio la extracción de datos de jugadores de fútbol desde una web pública.



Estado del Arte



On Multi-Thread Crawler
Optimization for Scalable
Text Searching

Autores

Guang Sun, Huanxin Xiang,
Shuanghu Li, 2019

Problema

Bajo rendimiento en
crawlers secuenciales sobre
grandes volúmenes de
texto.

Técnicas y Resultados

Técnicas: Multithreading + BFS/DFS

Resultados: Reducción del tiempo de scraping de ~1000s a 273s.

Estado del Arte



A Cloud-based System for
Scraping Data from
Amazon Product Reviews

Autores

Ryan Woodall, Douglas
Kline, Ron Vetter, Minoo
Modaresnezhad, 2022

Problema

Necesidad de extraer y
procesar reseñas de
productos a gran escala.

Técnicas y Resultados

Técnicas: Arquitectura en la nube, Azure Function, microservicios, SQL
Resultados: Sistema escalable, modular e integrado a flujos ETL.

Estado del Arte



Horizontally Scalable Web
Crawler using
Containerization and a
GUI

Autores

Ansuman Prusty, Pavan
Kancherlapalli, Roland
Schiebel, Aniket Shah,
Aditya Suresh, Oscar Mejia,
2020

Problema

Limitaciones en sistemas
monolíticos de scraping.

Técnicas y Resultados

Técnicas: Docker, Kubernetes, interfaz gráfica de usuario
Resultados: Escalabilidad horizontal; múltiples instancias de scraping en
paralelo sin interferencias.

Web scraping

Técnica de extracción automatizada de datos desde sitios web. Utiliza programas que navegan por páginas web y recogen información útil como precios, descripciones o contenido específico.

Parallel computing

Modelo de procesamiento donde se realizan múltiples operaciones simultáneamente usando varios procesadores o núcleos del dispositivo. Optimiza el tiempo de ejecución de las tareas al distribuir la carga de trabajo.

Marco Teórico

Docker containers


Tecnología que permite ejecutar aplicaciones en entornos aislados con todas sus dependencias, sin afectar el sistema operativo. Docker es la herramienta más popular para implementar contenedores.

Cloud computing


Modelo de entrega de servicios que ofrece recursos informáticos a través de Internet. Los usuarios pueden acceder a estos servicios desde cualquier lugar, sin necesidad de tener una infraestructura costosa.




Metodología



Metodología




Especificaciones



- **Procesador:** Intel Core i9-7900X
- **Sistema Operativo:** Windows 11
- **Memoria RAM:** 16 GB
- **Cantidad de procesadores:** 16



Resultados




Medida	Secuencial	Paralelo
Jugadores procesados	1000	1000
Tiempo de ejecución	70 minutos	2.69 minutos
Tiempo por jugador	4.2 segundos	0.16 segundos

$$\text{Speedup} = 70 / 2.69$$

$$\text{Speedup} = 26.02$$

Referencias

- [1] R. Mitchell, Web Scraping with Python: Collecting More Data from the Modern Web, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2018.
- [2] A. Grama, A. Gupta, G. Karypis, y V. Kumar, Introduction to Parallel Computing, 2ª ed., Boston, MA, EE. UU.: Addison-Wesley, 2003.
- [3] D. Merkel, "Docker: Lightweight Linux Containers for Consistent Development and Deployment," Linux J., vol. 2014, no. 239, Art. no. 2, Marzo 2014. [En l'ínea]. Disponible en: <https://dl.acm.org/doi/10.5555/2600239.2600241>
- [4] M. Armbrust et al., "A View of Cloud Computing," Communications of the ACM, vol. 53, no. 4, pp. 50–58, Abril 2010. [En l'ínea]. Disponible en: <https://doi.org/10.1145/1721654.1721672>
- [5] G. Sun, H. Xiang, y S. Li, "On Multi-Thread Crawler Optimization for Scalable Text Searching," Journal on Big Data, vol. 1, no. 2, pp. 89–106, 2019. [En l'ínea]. Disponible en: <https://pdfs.semanticscholar.org/1545/432272c6c4c352416f7ad29bcfb26550d840.pdf>
- [6] R. Woodall, D. Kline, R. Vetter, y M. Modaresnezhad, "A Cloud-based System for Scraping Data from Amazon Product Reviews at Scale," Journal of Information Systems Applied Research, vol. 15, no. 3, pp. 24–31, 2022. [En l'ínea]. Disponible en: <https://jisara.org/2022-15/n3/JISARv15n3.pdf#page=24>
- [7] A. Prusty, O. Mejia, A. Shah, P. Kancherlapalli, A. Suresh, y R. Schiebel, "Horizontally Scalable Web Crawler using Containerization and a Graphical User Interface," International Journal of Engineering Research & Technology (IJERT), vol. 9, no. 5, pp. 292–297, 2020. [En l'ínea]. Disponible en: <https://pdfs.semanticscholar.org/b8dd/7f8a92065fbb93b1306b37730096303067fa.pdf>
- [8] M. A. Khder, "Web Scraping or Web Crawling: State of Art, Techniques, Approaches and Application," Int. J. Advance Soft Compu. Appl., vol. 13, no. 3, pp. 145–160, 2021. [En l'ínea]. Disponible en: doi.org/10.15849/IJASCA.211128.11
- [9] W. P. Petersen y P. Arbenz, Introduction to Parallel Computing, Oxford University Press, 2004.
- [10] E. Casalicchio and V. Perciballi, "Measuring Docker Performance: What a Mess!!!," in Proceedings of the ICPE '17 Companion, L'Aquila, Italy, 2017, pp. 81–84, [En l'ínea]. Disponible en: doi.org/10.1145/3053600.3053605.
- [11] S. P. Mirashe and N. V. Kalyankar, "Cloud Computing," Journal of Computing, vol. 2, no. 3, pp. 78–82, Mar. 2010. [En l'ínea]. Disponible en: <https://arxiv.org/abs/1003.4074>



¡Muchas Gracias!